

Investigação Experimental de Deep Q-Networks (DQN)

Autor: Cleiver Batista da Silva Junior (individual)

Fork: [CleiverJr/t-zero-learning](#)

Algoritmo: [algorithms/dqn.py](#)

W&B: [projeto dqn-assignment](#) (24 runs; IDs nas tabelas)

Implementação Algorítmica (Partes 1 e 2): `ReplayBuffer.add` grava dados com ponteiro circular FIFO (`pos = (pos+1) % capacity`), sobrescrevendo a transição mais antiga. `sample` extrai amostras aleatórias uniformes com reposição nos slots preenchidos. `compute_td_targets` avalia $y = r + \gamma \cdot \max_{a'} Q_{\text{target}}(s', a') \cdot (1 - d)$ usando a target network; truncamentos de 500 passos mantêm bootstrap e tensores são achatados para shape $(B,)$. Validado via `pytest tests/test_dqn.py` (7/7 testes aprovados).

Protocolo Experimental (Harness): Todos os runs utilizam `configs/dqn_cartpole.yml` (500k passos de treino, $\epsilon: 1.0 \rightarrow 0.05$ em 50% do treino, taxa de aprendizado 2.5×10^{-4}), alterando apenas a variável da questão via `--override`. **Todas as configurações foram executadas com 2 seeds** (seed 1 = linha contínua, seed 2 = tracejada). Referência pontilhada nos gráficos: $Q^* = 1/(1 - \gamma) = 100$.

QUESTÃO 01

Frequência de Sincronização da Target Network

`dqn.target_network_frequency` ∈ {1, 50, 500, 10000, 50000}

PREVISÃO TEÓRICA: Com `tnf=1`, o alvo móvel contínuo causará realimentação positiva de superestimação em `q_values`, explodindo a perda e colapsando o retorno. Com `tnf` muito grande, o alvo quase estático manterá a `td_loss` baixa e treino estável, porém a propagação do valor será excessivamente lenta.




Fig. 1 — Retorno médio móvel (100 ep.), TD Loss (escala log com EMA 0.9) e Q médio predito (symlog) por tnf. Seed 1 contínua, Seed 2 tracejada.

tnf	Retorno Final (s1 / s2)	Eval Greedy (s1 / s2)	Q máx.	Q Médio >400k	TD Loss Mediana	W&B Run IDs (s1, s2)
1	215 / 198	223 / 208	2631 / 2931	69 / 70	60 / 55	nxv89hnf, 68hrq80o
50	500 / 130	500 / 479	1208 / 1053	103 / 212	4.8 / 3.0	7z89c72w, 51ye09dc
500 (baseline)	500 / 485	500 / 500	216 / 232	103 / 98	0.24 / 0.48	5w0roffb, ai4c257z
10000	130 / 130	115 / 130	37.5 / 37.5	33 / 35	0.06 / 0.11	yggog0vi, 1u52wg0d
50000	372 / 111	467 / 107	10.3 / 9.9	9.5 / 9.0	0.016 / 0.014	e9b9ui66, 09hrkdph

MECANISMO & ANÁLISE: A *target network* fixa temporariamente os rótulos de regressão, quebrando a perigosa circularidade do alvo de Bellman. Com `tnf=1`, essa âncora é perdida: o operador `max` seleciona sistematicamente erros positivos locais, que viram alvo imediato e amplificam-se a cada passo. Conforme exposto em `losses/q_values`, `Q` atinge ~1300 em 100k passos e atinge **2600–2931** (26–29× o teto físico teórico de 100), levando a `losses/td_loss` a 10^4 e provocando o colapso abrupto do retorno (seed 1 despenca de ~290 para ~20 no pico de `Q`). No extremo oposto (`tnf=10000` e `50000`), a `td_loss` é artificialmente minúscula (mediana 0.016 em 50k, 15× menor que o baseline) porque a rede se ajusta trivialmente a um alvo quase estático, mascarando que os valores estão errados e a política é ineficaz (retorno estagnado em ~110–130). O gráfico de `losses/q_values` comprova o mecanismo: a propagação de Bellman ocorre em apenas 1 passo por sincronização ($Q \approx \sum_{i < k} \gamma^i$), formando degraus visíveis. Com `tnf=50000` (~9 sincronizações), `Q` estagna em **9.5**; com `tnf=10000` (~49 sincronizações), atinge **37.5** (teórico 38.9). A rede só "enxerga" ~10–40 passos à frente, sendo incapaz de diferenciar equilíbrios longos de falhas distantes. **Previsões plenamente confirmadas.**

PREVISÃO TEÓRICA: Buffers minúsculos devem gerar batches com forte correlação temporal e esquecimento catastrófico de estados de queda, provocando oscilações severas no retorno e ruído em Q. Buffers excessivos devem atrasar a convergência ao reter por muito tempo dados da fase puramente exploratória ($\epsilon \approx 1$). Esperava-se colapso já com 200.




Fig. 2 — Retorno médio móvel (100 ep.) e Q médio predito por tamanho de buffer (batch_size = 128 fixo). Seed 1 contínua, Seed 2 tracejada.

Buffer	Retorno Final (s1 / s2)	1º Passo com Retorno ≥ 450	Q máx.	Q >400k: Média $\pm$ Desvio	W&B Run IDs (s1, s2)
16	240 / 415	428k / nunca	205 / 257	131 $\pm$ 43 / 174 $\pm$ 58	zyf6boas, uoeeq6pd
64	385 / 284	438k / nunca	216 / 230	158 $\pm$ 41 / 124 $\pm$ 40	11jpsr7u, 5yun2dex
200	500 / 500	240k / 243k	257 / 269	112 $\pm$ 5 / 109 $\pm$ 9	sjlrp5u7, 4uwqh0tq
2000	497 / 482	250k / 237k	205 / 222	100 $\pm$ 5 / 101 $\pm$ 6	nznb3q7v, 9aqf7dgw
10000 (baseline)	500 / 485	244k / 245k	216 / 232	103 $\pm$ 1 / 98 $\pm$ 6	5w0roffb, ai4c257z
100000	497 / 414	405k / 447k	354 / 529	101 $\pm$ 2 / 108 $\pm$ 3	k9jj7qlv, p0z6nmdh

MECANISMO & ANÁLISE: A redução drástica da capacidade do buffer decompõe-se em dois prejuízos distintos:

(1) Correlação intra-batch: Com `buffer=16` e `batch=128`, o minibatch repete as mesmas ~16 transições consecutivas cerca de 8 vezes. Elas advêm de um mesmo segmento temporal de trajetória, violando a premissa de dados independentes (i.i.d.). O gradiente sobreajusta à circunstância momentânea da física local em vez da distribuição global do espaço de estados, gerando a larga banda de ruído e alta variância documentada em `losses/q_values` (desvio padrão na fase final de 40–58, contra 1–6 no baseline).

(2) Cobertura e esquecimento catastrófico: A rede acessa apenas os últimos 16–64 passos. À medida que a política melhora, o buffer é rapidamente preenchido por estados equilibrados próximos ao centro. Transições de queda deixam de ser armazenadas e revistas, de modo que a rede esquece a precificação do perigo. Sem essa penalização, os valores Q nessas bordas derivam livremente para cima (média de Q chega a 124–174 após 350k passos, violando o teto de 100). Ao adentrar tais estados no ambiente, o agente falha, o retorno desaba bruscamente (ex.: `buffer=64` despencando de ~425 para ~175 aos 340k) e o aprendizado entra em ciclos intermitentes de reaprendizado sem estabilização em 500.

A previsão do limiar foi parcialmente refutada: `buffer=200` convergiu tão eficientemente quanto o baseline (~240k passos), comprovando que no CartPole 200 passos bastam para fornecer diversidade representativa da dinâmica inicial. No outro extremo, o `buffer=100000` reteve por tempo excessivo experiências obsoletas da fase inicial aleatória (ϵ alto), postergando a convergência (atingiu retorno ≥ 450 apenas aos 405k–447k passos) e elevando o pico inicial de Q (354–529), embora sem desestabilizar o platô final, confirmando a lentidão prevista.

PREVISÃO TEÓRICA

O valor assintótico de Q deve convergir para o limite geométrico $1/(1 - \gamma)$: 10, 100 e 1000 para $\gamma = 0.9, 0.99$ e 0.999 . $\gamma = 0.9$ terá horizonte curto (~10 passos), incapaz de detectar quedas graduais do pêndulo. $\gamma = 0.999$ resolverá a tarefa, mas com alvos 10x maiores, maior magnitude de TD loss e potencial instabilidade numérica.

JUSTIFICATIVA DAS MÉTRICAS SELECIONADAS

`charts/episodic_return_mean_last100` afere o desempenho da política. `losses/q_values` com as retas $1/(1 - \gamma)$ valida diretamente a escala do valor e o horizonte preditivo. `losses/td_loss` (em log) evidencia que o erro quadrático cresce com a escala dos alvos (Q^2) e não pode ser comparado diretamente entre diferentes γ . `charts/epsilon` foi omitido por ser idêntico em todas as configurações.




Fig. 3 — Retorno médio móvel (100 ep.), Q médio predito (symlog; pontilhado teórico = $1/(1-\gamma)$) e TD Loss (log) para cada γ . Seed 1 contínua, Seed 2 tracejada.

γ	Retorno Final (s1 / s2)	Eval Greedy (s1 / s2)	1º Passo com Retorno ≥ 450	Q Médio >400k (s1 / s2)	TD Loss Mediana	W&B Run IDs (s1, s2)
0.9	355 / 272	161 / 285	443k / nunca	10.0 / 9.8	0.034 / 0.024	0u39md1a, x5wx63an
0.99 (baseline)	500 / 485	500 / 500	244k / 245k	103 / 98	0.24 / 0.48	5w0roffb, ai4c257z
0.999	498 / 500	500 / 500	248k / 251k	1252 / 1310	6.5 / 5.9	6g6ode8m, x2ok2xpa

MECANISMO & ANÁLISE: A evolução de `losses/q_values` valida precisamente o comportamento teórico assintótico: Q converge rigorosamente para **10.0 ($\gamma = 0.9$)**, **~100 ($\gamma = 0.99$)** e **~1250–1310 ($\gamma = 0.999$)**. Em $\gamma = 0.999$, registra-se superestimação de 25–30% acima de 1000, fruto da amplificação do viés positivo do operador max sobre alvos de grande escala. Com $\gamma = 0.9$, o horizonte temporal efetivo é de apenas ~10 passos. O retorno acumulado de uma trajetória que cai em $T = 30$ passos atinge $(1 - 0.9^{30})/0.1 \approx 9.58$, tornando a diferença de valor para uma trajetória perfeita (10.0) inferior a 0.42. Essa margem mínima é soterrada pelo ruído intrínseco da regressão; consequentemente, o agente só reage a tombos iminentes e negligencia velocidades angulares ou derivas lentas do carrinho em direção à borda, oscilando continuamente e estagnando em retorno medíocre (272–355). Com $\gamma = 0.999$, o horizonte de planejamento engloba todo o episódio de 500 passos, igualando o retorno máximo (500) e a velocidade do baseline. O impacto ocorre diretamente na `losses/td_loss`: alvos 10x maiores aumentam a perda em mais de uma ordem de grandeza (mediana ~6.2 vs 0.36) e induzem picos severos de até $\sim 10^3$ devido a gradientes de alta magnitude. No entanto, nesta tarefa esses picos não desestabilizaram a política, mantendo avaliação gulosa ótima (500 ± 0 em ambas as seeds). **Previsões plenamente confirmadas.**