

Atividade 06: Policy Gradient com Actor-Critic Síncrono (A2C)

Cleiver Batista da Silva Junior (individual) · Fork Oficial: github.com/CleiverJr/t-zero-learning · Logs W&B: [projeto a2c-assignment](#)

Ambientes: CartPole-v1 & LunarLander-v3

IMPLEMENTAÇÃO ALGORÍTMICA (PARTES 1, 2 E 3)

1. Retorno de n-passos com Bootstrap (algorithms/a2c.py): Acumulação retroativa de horizonte finito $R_t = r_t + \gamma(1 - d_t)R_{t+1}$, inicializada no passo terminal por $R_T = V(s_T)$. A máscara booleana $(1 - d_t)$ interrompe estritamente a propagação nos limites dos episódios de forma desacoplada entre os ambientes.

2. Perda de Política e Isolamento de Gradientes: Perda $L_\pi = -\frac{1}{B} \sum \log \pi(a_i|s_i) A_i$, onde o peso de vantagem $A_i = (R_i - V(s_i))$, `detach()` é explicitamente desconectado do grafo computacional para impedir o vazamento espúrio de gradiente da política para o crítico.

3. Arquitetura Ator-Crítico Categórica (networks/discrete_actor_critic.py): Rede neural MLP com cabeças separadas parametrizando $\pi(a|s) \sim \text{Categorical}(\text{logits})$ e função valor escalar $V(s)$.

PROTOCOLO & RIGOR EXPERIMENTAL

Configuração Base: configs/a2c_cartpole.yml (500k timesteps, 8 ambientes, $n=5$, $\text{lr}=7 \times 10^{-4}$, $\gamma=0,99$, $c_v=0,5$, $c_e=0,01$).

Reprodutibilidade Estocástica: Varreduras por `--override` executadas obrigatoriamente com 2 seeds independentes (Linha cheia = Seed 1; Tracejada = Seed 2).

Métricas & Isolamento: Retorno final reportado como a média dos últimos 20% do treinamento. A taxa de passos por segundo (SPS) foi aferida em execução isolada dedicada (200k passos sem concorrência de CPU) para eliminar distorções de contenção de hardware.

Q1 — Atores em Paralelo: Descorrelação de Trajetórias e Eficiência Amostral num_envs ∈ {1, 8, 32, 64} + Controle

HIPÓTESE TEÓRICA (A PRIORI)
Aumentar o número de atores simultâneos em métodos on-policy quebra a dependência sequencial temporal das transições, reduzindo drasticamente a variância do estimador do gradiente de política e suprimindo o ruído de `policy_loss`. O paralelismo vetorial deve escalar o SPS até o limite de núcleos físicos da CPU. Contudo, como o tamanho do lote de cada atualização é $B = \text{num_envs} \times \text{num_steps}$, valores excessivamente altos de `num_envs` reduzirão a quantidade de passos de gradiente executados dentro do orçamento fixo de 500k transições, desacelerando o aprendizado.




Figura 1: Curvas de aprendizado (retorno médio dos últimos 100 episódios), ruído bruto de `policy_loss` (escala symlog) e taxa SPS aferida em isolamento físico por configuração de paralelismo.

num_envs	Lote (Nxn)	Atualizações	Retorno Final (s1 / s2)	Eval Greedy (s1 / s2)	Desvio σ (policy_loss)	Pico Negativo	SPS Isolado	Run IDs (s1, s2)
1	5	100.000	351 / 315	462 / 256	4,5 / 7,8	-63 / -104	4.056	7zz8i4sv, tdw48yei
8 (Baseline)	40	12.500	478 / 461	500 / 482	1,4 / 1,3	-14 / -10	22.683	5vukxjqp, q77wk364
32	160	3.125	417 / 469	500 / 375	0,74 / 0,84	-3,6 / -5,0	47.593	u1gors56, o1mbpzz8
64	320	1.562	221 / 159	267 / 167	0,57 / 0,46	-1,8 / -0,3	38.843	jikj7s7y, enq07wm0
Controle: 1 env, n=40	40	12.500	386 / 405	454 / 298	11,2 / 9,7	-54 / -72	—	abqwmzce, vm06tqa6

Mecanismo de Descorrelação On-Policy: Algoritmos de gradiente de política on-policy não utilizam memória de replay; portanto, as amostras coletadas por um ator isolado são fortemente correlacionadas no tempo, representando um recorte microscópico e enviesado da dinâmica local do episódio. Isso explica os picos destrutivos de `policy_loss` observados com `num_envs=1` (-63 e -104) e seu elevado desvio padrão ($\sigma \approx 7,8$). Ao paralelizar atores em sincronia, cada ambiente ocupa uma região independente do espaço de estados, de modo que a agregação síncrona aproxima o gradiente amostrado de sua esperança matemática assintótica $E[\nabla_{\theta} \log \pi_{\theta}(a|s) A(s,a)]$, estabilizando a perda em uma faixa suave ($\sigma \approx 0,5$ em 64 envs).

Isolamento Categórico: Volume do Lote vs. Independência Amostral: Uma ambiguidade teórica clássica é se o ganho de desempenho provém do aumento do lote ($B = N \times n$) ou da independência das amostras. O **run de controle** (1 ambiente com $n=40$) soluciona essa questão: ele replica com exatidão o lote de 40 transições e as 12.500 atualizações do baseline (8×5), mas exibe o maior ruído de toda a série experimental ($\sigma = 11,2$) e estagnação no retorno (386–405 vs 461–478). Isso comprova que a virtude do A2C reside na *descorrelação estocástica dos múltiplos pontos de partida*, e não no mero volume bruto de dados. Em contrapartida, com 64 ambientes, a variância é mínima, mas o orçamento de 500k passos comporta apenas 1.562 atualizações, resultando em severo subajuste. O SPS atinge pico de 47.593 em 32 atores (aceleração de 11,7x), retraindo em 64 devido à sobrecarga de chaveamento de contexto no processador de 10 núcleos.

HIPÓTESE TEÓRICA (A PRIORI)
O horizonte n comanda o balanço clássico entre viés e variância. Em $n=1$, o alvo aproxima-se do bootstrap de 1 passo ($r + \gamma V$), exibindo baixa variância mas viés máximo herdado dos erros do crítico. Em $n=128$, o alvo aproxima-se de Monte Carlo puro, livre de viés mas sujeito à dispersão cumulativa da trajetória, elevando a `value_loss`. Como a vantagem $A_t = R_t - V(s_t)$ acopla diretamente o crítico ao ator, falhas no crítico devem desestabilizar o aprendizado da política.




Figura 2: Curvas de retorno médio, evolução da `value_loss` (escala log) e dinâmica da variância explicada (EV) sob diferentes horizontes de rollout n .

num_steps	Lote	Retorno Final (s1 / s2)	Eval Greedy	Value Loss Mediana	EV Final (s1 / s2)	Média Pesos A	Desvio Pesos A	Run IDs (s1, s2)
1	8	431 / 433	500 / 500	~0,00	0,26 / 0,90	-0,25 / -0,12	0,70 / 0,36	jj88rgp5, agglp2k7
5 (Baseline)	40	478 / 461	500 / 482	~0,00	0,70 / 0,44	-0,07 / -0,71	0,39 / 2,39	5vukxjqp, q77wk364
32	256	340 / 485	180 / 500	51 / 77	0,00 / 0,30	0,81 / 1,09	10,1 / 8,1	immo8y6, dfms8aic
128	1024	400 / 414	371 / 461	505 / 498	0,00 / 0,00	23,5 / 23,4	17,8 / 17,7	twqv3nh9, 9g7tdlj1

Propagação do Erro do Crítico ao Ator: Em $n=128$, a soma empírica de recompensas sem amortecimento por bootstrap infla drasticamente a variância do alvo, fazendo a `value_loss` explodir de ~0 para patamares superiores a **500**. Esse erro destrói a calibração da vantagem: os pesos do gradiente passam a ter média espúria de +23,5 e desvio de 17,8 (contra média centrada em zero no baseline). Quando o crítico subestima sistematicamente os retornos, o peso da vantagem torna-se uniformemente positivo, reforçando qualquer ação executada e impedindo a diferenciação relativa exigida pela subida de gradiente.

A Armadilha Analítica da Explained Variance em Micro-Lotes: Em $n=1$, a seed 2 registra EV = 0,90, aparentando excelência estatística. Trata-se de uma armadilha métrica: com $N=8$ e $n=1$, o lote possui apenas 8 transições altamente redundantes cujos alvos $r + \gamma V(s')$ foram sintetizados pela própria rede de valor naquele mesmo instante. Explicar a variância de amostras autorreferenciadas e colineares é matematicamente trivial e não reflete acurácia preditiva sobre o valor real do estado. Já em $n \geq 32$, a EV estaciona em 0,00 porque, com o bastão estabilizado, as trajetórias alcançam retornos homogêneos; a variância do denominador $\text{Var}(y)$ colapsa para zero, tornando a métrica analiticamente instável.

Q3 — Regularização por Bônus de Entropia: Colapso Prematuro vs. Saturação Estocástica

HIPÓTESE TEÓRICA (A PRIORI)
O bônus de entropia impede que a política colapse prematuramente em ações determinísticas antes da exploração do espaço. Um coeficiente excessivo (0,1) fará o termo $-\beta H(\pi)$ dominar a função de perda, travando a entropia próxima da distribuição uniforme ($\ln 2 \approx 0,693$) e impedindo o equilíbrio fino. Com coeficiente nulo (0), a política deve convergir rapidamente no CartPole devido à extrema simplicidade e densidade de seu sinal de reforço.




Figura 3: Retorno médio e trajetória da entropia de Shannon da política categórica sob diferentes fatores de regularização β . Linha pontilhada indica o teto uniforme para 2 ações ($\ln 2 \approx 0,693$).

ent_coef	Retorno Final (s1 / s2)	Eval Greedy (s1 / s2)	1º Passo com Retorno ≥ 450	Entropia Final (s1 / s2)	Run IDs (s1, s2)
0 (Sem Bônus)	489 / 499	500 / 500	129k / 131k	0,47 / 0,31	4223izo4, dsyhmsz
0,01 (Baseline)	478 / 461	500 / 482	228k / 274k	0,55 / 0,55	5vukxjqp, q77wk364
0,1 (Excessivo)	368 / 340	357 / 425	Nunca Atingiu	0,60 / 0,60	34521kv7, ue9iv084

Mecanismo de Degradação por Estocasticidade Forçada: Em $\text{ent_coef}=0.1$, a entropia estabiliza-se rigidamente em 0,60 durante todo o treino. A maximização da desordem supera o incentivo de ganho de recompensa, impedindo que os logits converjam para distribuições assertivas. Em estados limítrofes de tombamento do bastão, a política injeta perturbações aleatórias que abortam prematuramente o episódio, estagnando o retorno médio em 340–368 e impedindo o cumprimento da meta de 450.

A Benevolência Estrutural do CartPole: Com $\text{ent_coef}=0$, a política reduz livremente sua entropia para 0,31–0,47 e atinge o limiar de excelência (≥ 450) em apenas **129k passos** — duas vezes mais rápido que o baseline. O CartPole permite aprendizado perfeito mesmo sem entropia porque conjuga três propriedades favoráveis: (i) espaço de ação binário ($|A| = 2$, onde um colapso acidental ainda retém 50% de chance de correção); (ii) recompensas densas e imediatas (+1 por passo); e (iii) terminação no erro com crédito local imediato. Em domínios complexos com recompensas esparsas ou múltiplos graus de liberdade (como LunarLander com $|A| = 4$ ou Montezuma's Revenge), $\text{ent_coef}=0$ provoca colapso irreversível em bacias de atração subótimas antes da descoberta da recompensa.

HIPÓTESE TEÓRICA (A PRIORI)
Subtrair uma linha de base independente da ação não altera a esperança matemática do gradiente de política ($E_{a \sim \pi}[\nabla_{\theta} \log \pi_{\theta}(a|s) V(s)] = 0$), mas atua como operador crucial de redução de variância. Sem baseline ($w = R$), a variância dos pesos deve explodir. Dado que as recompensas no CartPole são estritamente positivas ($r_t = +1 \Rightarrow R > 0$), todo gradiente impulsionará a probabilidade da ação sorteada, deflagrando um ciclo de feedback positivo que colapsará a entropia para zero e paralisará o aprendizado.




Figura 4: Dinâmica comparativa com baseline ($A = R - V$) e sem baseline ($A = R$): retorno médio, desvio padrão $\sigma(A)$ (escala log), média amostral $\mu(A)$ e colapso catastrófico da entropia da política.

use_baseline	Retorno Final (s1 / s2)	Eval Greedy (s1 / s2)	Média Pesos A (Fim)	Desvio Pesos A (Fim)	Entropia Final (s1 / s2)	Policy Loss Mínima	Run IDs (s1, s2)
Sim — R - V(s) (Baseline)	478 / 461	500 / 482	-0,07 / -0,71	0,39 / 2,39	0,55 / 0,55	-14 / -10	5vukxjqp, q77wk364
Não — R (Ablação REINFORCE)	98 / 97	57 / 95	39,2 / 39,5	16,1 / 16,3	0,004 / 0,007	0,0 / 0,0	kiwifws0, 9ogc2rkl

Validação Empírica da Redução de Variância: Os resultados empíricos confirmam o postulado teórico de Williams: o baseline preserva a média empírica centrada em zero ($\mu \approx -0,39$), enquanto sem baseline a média salta para +39,3 e o desvio padrão cresce entre **7 e 41 vezes** ($\sigma = 16,2$ vs $0,39$). Sem a âncora de $V(s)$, o estimador do gradiente torna-se excessivamente ruidoso, exigindo volumes impraticáveis de dados para que a direção ótima emergja.

O Fenômeno do Colapso por Realimentação Positiva: No CartPole, o retorno empírico R é invariavelmente positivo ($R \in [1, 500]$). Como consequência, o termo de perda $-\log \pi(a|s) \cdot R$ é estritamente côncavo e a `policy_loss` atinge mínimo idêntico a **0,0** (jamais negativando, ao passo que com baseline atinge -14). Sob pesos estritamente positivos, *toda ação amostrada tem sua probabilidade incrementada*. A única via de declínio de uma ação inferior é ser selecionada menos vezes que a alternativa. Isso dispara uma realimentação viciosa: a ação ligeiramente mais frequente no início é ainda mais reforçada até monopolizar a distribuição categórica. A entropia colapsa instantaneamente para **0,004** (determinismo espúrio), paralisando o retorno médio em píffios 57–95.

Extra — LunarLander-v3: Transferência, Ajuste Sistemático e Limitações Estruturais `configs/a2c_lunarlander.yml` (Meta ≥ 200)




Figura 5: Trajetória de aprendizado no LunarLander-v3 (retorno médio dos últimos 100 episódios) e decaimento da entropia ao longo do refinamento paramétrico até 20M passos. Linhas pontilhadas indicam o limiar de resolução (200) e a entropia uniforme para 4 ações ($\ln 4 \approx 1,386$).

Configuração Paramétrica Investigada	Timesteps	Pico de Retorno	Retorno Final (Treino)	Eval Greedy (10 Ep.)	Entropia Final
lr 7e-4, n=16, 16 envs, ent 0,01 (Transposição Direta CartPole)	5M	4	-126	-112	0,72
lr 3e-4, n=32, 16 envs, ent 0,01	5M	39	-92	-36	0,87
lr 1e-4, n=32, 16 envs, ent 0,001	8M	12	-23	-9	0,93
lr 1e-4, n=32, 16 envs, ent 0 (Sem Regularização)	8M	14	-42	-54	0,90
lr 1e-4, n=64, 16 envs, ent 0,001	8M	151	115	19	0,82
lr 1e-4, n=64, 16 envs, ent 0,001 (Treino Estendido)	20M	174	121	157 ± 106	0,66

Diagnóstico Rigoroso dos Gargalos e Desempenho Quase-Resolvido: A transposição ingênua dos parâmetros do CartPole colapsa catastrófica-mente para -126 devido à amplitude de recompensa (-400 a +250) e termo terminal de impacto (± 100). A estabilização exigiu amortecimento da taxa de aprendizado ($lr \rightarrow 1 \times 10^{-4}$), expansão do horizonte ($n=64$, permitindo propagar o sinal terminal sem depender de dezenas de bootstraps ruidosos) e compressão da entropia (0,001, essencial para mitigar o desperdício de combustível). Na melhor configuração com 20M passos, a política atinge **157 ± 106 na avaliação greedy**. A análise dos 10 episódios revela que **6 episódios obtiveram pouso perfeito com retornos entre 201 e 240**, 2 colidiram e 1 desceu fora do centro. A meta média de 200 não foi atingida em virtude de três limitações intrínsecas: (1) *Ausência de GAE e Normalização de Vantagem*: sem decaimento λ nem padronização em batch, episódios de queda (-400) geram choques de gradiente desproporcionais; (2) *Ineficiência Amostral On-Policy*: o A2C executa apenas uma etapa de descida por lote e descarta os dados, necessitando de ordens de magnitude a mais de interação que métodos off-policy ou PPO; e (3) *Exploração Residual*: a entropia decaiu para 0,66 (de um teto de 1,39); acelerar esse decaimento manualmente (`ent_coef=0`) causou colapso prematuro (-42).