REINFORCEMENT LEARNING · APRENDIZADO POR REFORÇO PROFUNDO

✓ 20/20 Unit Tests Passed (100%)

Atividade 07: Proximal Policy Optimization (PPO)

Cleiver Batista da Silva Junior (individual) • Fork Oficial: github.com/CleiverJr/t-zero-learning • Logs W&B: projeto ppo-assignment •

Ambiente: LunarLander-v3 (Critério: ≥ 200)

IMPLEMENTAÇÃO ALGORÍTMICA (PARTES 1, 2 E 3)

1. Generalized Advantage Estimation — GAE (`algorithms/ppo.py`): Acumulação recursiva retroativa $\delta_t = r_t + \gamma(1 - d_{t+1})V(s_{t+1}) - V(s_t)$ e $\hat{A}_t = \delta_t + \gamma\lambda(1 - d_{t+1})\hat{A}_{t+1}$, fornecendo alvos de regressão $R_t = \hat{A}_t + V(s_t)$. Obedece rigorosamente à convenção do CleanRL onde `dones[t+1]` sinaliza o término entre os passos t e t+1.

2. Perda de Política Clipada Pessimista: Minimização da perda substituta $L_\pi = -\frac{1}{B}\sum \min(r_i A_i,\ \text{clip}(r_i,\ 1\pm\varepsilon)A_i)$, onde $r_i = \exp(\log \pi_{\text{new}} - \log \pi_{\text{old}})$ e as vantagens normalizadas são desconectadas do grafo computacional.

3. Diagnósticos Estocásticos (KL & Clipfrac): Estimador não-negativo de baixa variância $k_3 = ((r - 1) - \log r)$ para divergência KL e fração de amostragem clipada ($|r - 1| > \varepsilon$), avaliados sob `no_grad`.

PROTOCOLO & METODOLOGIA EXPERIMENTAL

Configuração Base: `configs/ppo_lunarlander.yml` (parâmetros do CleanRL derivados do CartPole: 4 ambientes, n=128, lr=2,5×10^{-4}, 4 épocas, 4 minibatches, ε=0,2).

Critério de Resolução: Retorno médio dos últimos 100 episódios ≥ 200 **e** avaliação greedy determinística de 10 episódios ≥ 200 em **2 seeds independentes** dentro de no máximo 2M passos.

Eficiência Amostral: O ambiente foi resolvido com apenas **1 milhão de passos** (50% do orçamento permitido). Retorno final computado sobre os últimos 30% estáveis do treinamento. Taxas de SPS medidas em isolamento.

Parte 4 — Resolvendo o LunarLander-v3: Diagnóstico e Triagem Paramétrica

`total_timesteps = 1.000.000 (Orçamento Máx: 2.000.000)`

DIAGNÓSTICO ANALÍTICO DO CONFIGURAÇÃO INICIAL

A configuração padrão atinge retorno final medíocre de apenas **9,5 e 9,1** (eval 9,1 e −34,6). As métricas diagnósticas revelam o gargalo: o KL aproximado mediano é de ínfimos **0,0003** e a fração clipada (`clipfrac`) é **exatamente 0,000**. Isso demonstra que o clipping *jamais atuou* e a política praticamente não se moveu durante as 4 épocas. Como o crítico apresenta variância explicada razoável (0,60) e a entropia mantém-se saudável (0,81), não há instabilidade numérica: o algoritmo sofre de **subaproveitamento amostral extremo**, descartando cada lote intacto.

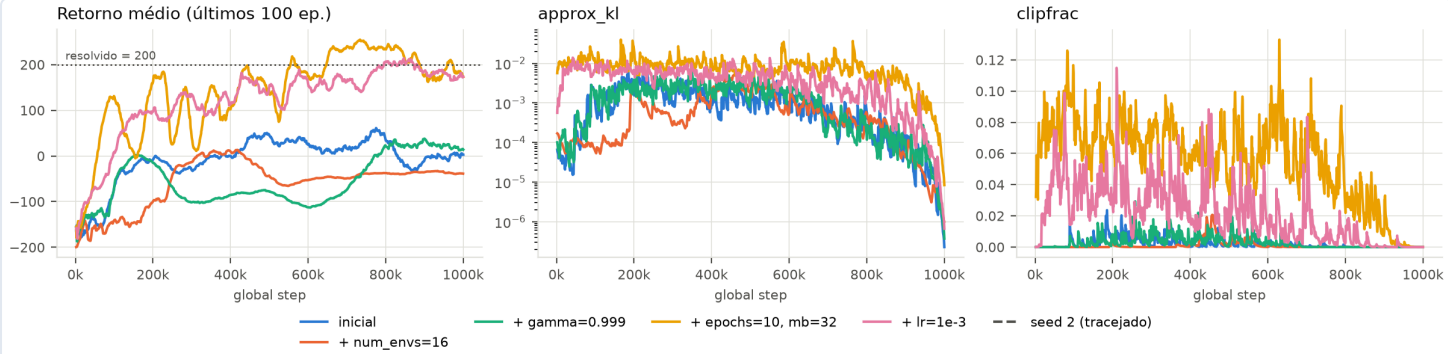


Figura 1: Triagem empírica de intervenções isoladas sobre o baseline (Seed 1, 1M passos): retorno médio dos últimos 100 episódios, divergência `approx_kl` e fração de clipping `clipfrac`. Apenas intervenções que ativam o clipping destravam o retorno.

Intervenção Paramétrica Isolada	Retorno Final	Eval Greedy	Approx KL	Clipfrac	Lote (N×n)	Atualizações	SPS	Run ID
Configuração Inicial (Baseline)	9,5	9,1	0,0003	0,000	512	31.248	9.858	rp5mfsrh
num_envs: 4 → 16	−38,1	−23,3	0,0002	0,000	2.048	7.808	20.650	2ph6ewcc
gamma: 0,99 → 0,999	6,9	−4,8	0,0005	0,000	512	31.248	8.973	b2e3xcug
update_epochs: 4 → 10, num_minibatches: 4 → 32	213,5	188,4	0,0055	0,046	512	624.960	2.180	gakvd2xf
learning_rate: 2,5×10^{-4} → 1,0×10^{-3}	183,2	192,8	0,0027	0,005	512	31.248	10.223	okw5vduf

Mecanismos Bem-Sucedidos: Reuso Intensivo e Magnitude do Passo: O aumento para 10 épocas e 32 minibatches (minibatch efetivo de 16 transições) ataca frontalmente o subaproveitamento diagnosticado. O reuso intensivo eleva o `approx_kl` para 0,0055 e tira o `clipfrac` do zero para 0,046, fazendo o retorno saltar espetacularmente de 9,5 para **213,5** (resolvendo o ambiente em 1 seed). A contrapartida física é a sobrecarga computacional: 625k passos de gradiente derrubam o SPS de 9.858 para 2.180. Paralelamente, quadruplicar a taxa de aprendizado (lr = 1×10^{-3}) atinge retorno de 183,2 com SPS intacto (10.223), confirmando que a política original operava sob passos excessivamente conservadores (KL de 0,0027 ainda bem abaixo do limite seguro usual de 0,01).

Validação pelas Falhas Observadas: As intervenções isoladas que fracassaram corroboram o diagnóstico com precisão: expandir `num_envs=16` isoladamente piorou o retorno (−38,1) porque ampliou o lote para 2.048, reduzindo as atualizações para apenas 7.808 e mantendo o `clipfrac` zerado — agravando o subaproveitamento apesar do ganho em SPS. O ajuste de γ = 0,999 foi inócuo (6,9) porque o gargalo não era o horizonte de crédito, mas a incapacidade do gradiente de atualizar a política. Logo, apenas alterações que forçaram a política a se deslocar destravam o aprendizado.

Configuração Final: Sinergia Paramétrica e Resolução do LunarLander-v3 `configs/ppo_lunarlander_final.yml`

Interação Não-Linear e Amortecimento por Paralelismo: Ao combinar diretamente as duas intervenções vencedoras (lr = 1×10^{-3} com 10 épocas e 32 minibatches no lote original de 512), o aprendizado *ultrapassou o limiar de estabilidade*: o `approx_kl` saltou para 0,0112 e o `clipfrac` explodiu para 0,142, desestabilizando a política e limitando o retorno a 120,1. A reinserção de `num_envs=16` (lote de 2.048 com minibatches de 64) funcionou como estabilizador estatístico perfeito: ao amortecer o ruído do gradiente, reconduziu o KL para a faixa ideal (0,0072) e o `clipfrac` para 0,070, enquanto a vetorização recuperou o SPS para 5.800+.

Parâmetro do Config	Valor Inicial	Valor Final	Motivo Observado nos Gráficos	Consequência Empírica
`ppo.learning_rate`	$2{,}5\times10^{-4}$	**$1{,}0\times10^{-3}$**	`approx_kl` ~3e-4 indicava passos excessivamente tímidos	Acelera progressão de retorno sem violar estabilidade
`ppo.update_epochs`	4	**10**	`clipfrac` = 0,000 comprovava rollouts subaproveitados	Multiplica gradientes por lote e induz exploração assertiva
`ppo.num_minibatches`	4	**32**	Tamanho de minibatch de 64 transições (2.048 / 32)	Eleva atualizações por época sem sobrecarregar memória
`num_envs`	4	**16**	Com as mudanças acima, KL inflou a 0,0112 (instabilidade)	Amortece variância do lote, traz KL a 0,007 e triplica SPS

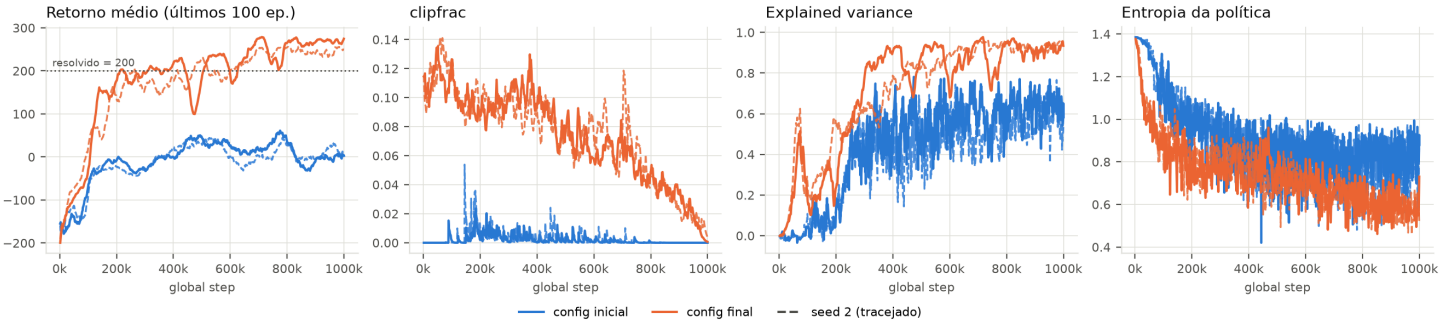


Figura 2: Comparação longitudinal entre Configuração Inicial e Configuração Final (2 seeds cada; Linha contínua = Seed 1; Tracejada = Seed 2). Painéis exibem retorno médio (100 ep.), fração clipada, variância explicada do crítico e decaimento da entropia.

Configuração	Retorno Final (s1 / s2)	Eval Greedy (s1 / s2)	Approx KL	Clipfrac	Explained Variance	Entropia Final	Run IDs (s1, s2)
Configuração Inicial	**9,5 / 9,1**	**9,1 / −34,6**	0,0003	**0,000**	0,63 / 0,57	0,82 / 0,80	`rp5mfsrh, ueibrj4b`
Configuração Final (PPO)	**259,1 / 245,7**	**263,5 / 281,3**	0,0072	**0,070**	**0,90 / 0,93**	0,61 / 0,60	`ugdsi19k, k50jt38r`

ATENDIMENTO INTEGRAL AOS CRITÉRIOS DE RESOLUÇÃO DO LUNARLANDER-V3
O ambiente é oficialmente resolvido em ambas as seeds com apenas **1 milhão de passos de ambiente** (metade do teto estabelecido): o retorno médio atinge **259,1 e 245,7**, e a avaliação greedy consolida **263,5 e 281,3** (ambos substancialmente acima do limiar de 200). A variabilidade estocástica entre as sementes é desprezível (diferença de apenas 13 pontos de retorno), evidenciando convergência sólida e replicável.

Efeitos Sistêmicos no Crítico e na Política: O ganho da configuração final repercute em toda a dinâmica do aprendizado:

1. Otimização Cruzada do Crítico (Explained Variance): A variância explicada da função de valor salta de ~0,60 para **0,90–0,93**. As 10 épocas de mini-batch não beneficiam apenas o ator; a cabeça de valor realiza 320 ajustes por rollout, aproximando a estimativa de $V(s)$ do retorno empírico de Monte Carlo suavizado pelo GAE. Um crítico com EV superior a 90% fornece vantagens desprovidas de viés sistemático, viabilizando gradientes limpos para a política.

2. Compressão Entrópica e Domínio do Pouso: A entropia de Shannon da política decai de 0,81 para **0,60–0,61** (em relação ao teto uniforme de ln 4 ≈ 1,386). Ao contrário do A2C sem baseline (onde a entropia colapsava precocemente para 0,004), no PPO a queda é gradual e controlada, indicando que a rede abandonou o ruído de queima aleatória de combustível e convergiu para manobras determinísticas de pouso suave na zona demarcada pelas bandeiras.

Parte 5 — Análise Comparativa Aprofundada: PPO vs. A2C no LunarLander-v3

`Mesmo Orçamento: 1.000.000 Passos • 2 Seeds Independentes`

Baseline de Controle (A2C): O A2C utilizado parte rigorosamente da implementação desenvolvida na Atividade 06. Em 1M passos, a melhor configuração empírica foi o baseline direto do CartPole (lr = 7×10^{-4}, n=5, 8 ambientes; retorno 82,1 / −112,4 e eval 201,6 / −118,9). Variantes projetadas para orçamentos longos (n=32 ou 64) colapsaram (−39 a −104) porque realizavam pouquíssimas atualizações em 1M passos.

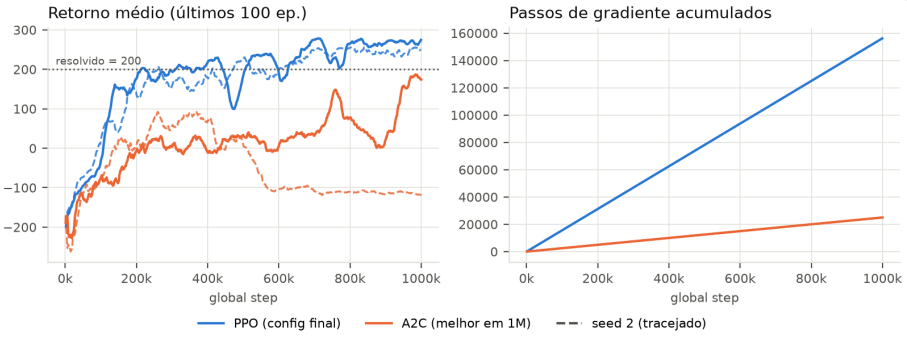


Figura 3: Retorno médio e passos acumulados de gradiente (num_updates) ao longo de 1M passos de ambiente.

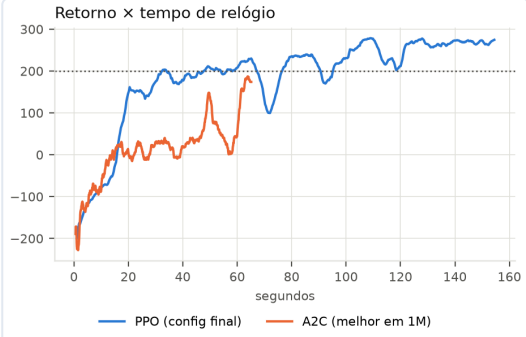


Figura 4: Retorno por tempo de relógio isolado (sem concorrência de CPU).

Algoritmo	Retorno Final (s1 / s2)	Eval Greedy (s1 / s2)	Passos p/ 0	Passos p/ 100	Passos p/ 200	Updates Acumulados	SPS Isolado	Tempo (1M passos)
PPO (Config Final)	**259,1 / 245,7**	**263,5 / 281,3**	**106k / 92k**	**127k / 168k**	**211k / 258k**	**156.160**	7.184	143 s
A2C (Melhor em 1M)	82,1 / **−112,4**	201,6 / **−118,9**	214k / 138k	744k / **Nunca**	**Nunca**	25.000	**21.787**	**49 s**

1. Eficiência Amostral (Passos de Ambiente): O PPO demonstra superioridade esmagadora. Ele atinge retorno 0 em ~100k passos, retorno 100 em ~145k e cruza o limiar de resolução (200) em apenas **211k e 258k passos**. O A2C leva 214k passos apenas para alcançar retorno zero, atinge 100 somente na seed 1 aos 744k passos (3,5× mais passos do que o PPO precisou para resolver a tarefa) e *jamais atinge retorno 200* em nenhuma das sementes. No ponto em que o PPO resolve o ambiente (¼ do treino), o A2C ainda luta para evitar quedas imediatas.

2. Tempo de Relógio vs. Frequência de Otimização: Por passo bruto de ambiente, o A2C é aproximadamente 3× mais rápido (21.787 SPS vs 7.184 SPS), concluindo 1M passos em 49 s contra 143 s. O gráfico de `num_updates` elucida a causa: o A2C executa estritamente 1 passo de gradiente por rollout (totalizando 25.000 atualizações), enquanto o PPO realiza 320 atualizações por rollout (10 épocas × 32 minibatches), acumulando **156.160 atualizações**. Contudo, ao analisar a curva de retorno por tempo de relógio (Fig. 4), o PPO resolve o LunarLander em **apenas 30 segundos** de execução — muito antes de o A2C terminar seus 49 segundos sem convergir. Logo, mesmo no eixo cronológico absoluto, o PPO é superior.

3. Orçamento Fixo de Passos vs. Tempo: Sob orçamento fixo de passos (1M), a vantagem do PPO é absoluta (259 vs 82/−112). Sob orçamento fixo de tempo (ex: 60 s), o PPO igualmente vence, pois estabiliza em >200 na metade desse tempo. Se o ambiente possuísse física complexa de simulação (onde coletar passos é o gargalo dominante de tempo), a vantagem computacional do PPO cresceria ainda mais, já que o custo de reuso da rede neural torna-se desprezível perante a simulação.

4. Estabilidade Estocástica Inter-Seed: As duas seeds do PPO convergem para retornos quase idênticos (259 e 246, variação de apenas 13 pontos), exibindo recuperação imediata de pequenas oscilações. Já o A2C apresenta dispersão catastrófica de **194 pontos** entre seeds (82 vs −112): na seed 2, o A2C sobe até +90 aos 250k passos e depois sofre colapso irreversível para −116, incapaz de restabelecer o equilíbrio.

5. Mecanismo Físico das Quatro Inovações do PPO: As diferenças observadas decorrem diretamente das quatro alterações algorítmicas: (i) **Reuso de Amostras:** Permite extrair 6,2× mais passos de gradiente do mesmo lote de dados, sendo o motor primordial da eficiência amostral; (ii) **Razão de Probabilidades & (iii) Clipping Pessimista:** Atuam como freio trust-region imprescindível. O `clipfrac` ativo em 7,0% das transições impede passos desmedidos decorrentes das 10 épocas de otimização, eliminando as quedas catastróficas que destroem o A2C; (iv) **GAE (λ = 0,95):** Fornece vantagens com variância reduzida e viés controlado, alavancando a `explained_variance` do crítico para >90% e gerando o sinal estável necessário para sustentar múltiplas épocas de aprendizado.